Teeth3DS 数据集介绍与 npy 转换指南

1. 概述

Teeth3DS 是公开的口内扫描牙齿分割与编号基准数据集：900 名患者、1800 个口扫模型（上颌、下颌各一个），每个网格顶点都标了 FDI 牙位号和牙齿实例号。它是 MICCAI 2022 挑战赛 3DTeethSeg'22 的官方数据。

项目	内容
规模	1800 个扫描 / 900 名患者，上下颌分开存储
标注	逐顶点：FDI 语义标签 `labels` + 实例标签 `instances`，0 = 牙龈
文件格式	网格 `.obj` + 标注 `.json`
划分	两套：3DTeethSeg 挑战赛划分、Teeth3DS 官方划分（均为病人级 train/test 列表）
评测指标	TLA（牙齿定位精度）、TIR（牙齿识别率）、TSA（分割精度），见仓库 `evaluation.py`
下载	osf.io/xctdy，共 6 个分包，需解压合并到同一目录
许可	数据 CC BY-NC-ND 4.0（非商用、禁止演绎发布）；代码 MIT
发布方	Udini（法国）、Inria Grenoble Morpheo 团队、Sfax 数字研究中心（突尼斯）

扩展版 **Teeth3DS+** 在原数据上增加了牙齿关键点（landmark）标注，用于 MICCAI 2024 的 3DTeethLand 挑战赛（约 340 个扫描）。另外，采集设备一般记为 Primescan、Trios 3、iTero Element 2 Plus 三种口扫仪。这两点凭记忆写的，大致准确，使用前请对照论文核实。

来源：3DTeethSeg_MICCAI_Challenges 仓库；论文 Teeth3DS (arXiv:2210.06094)、3DTeethSeg'22 (arXiv:2305.18277)。

2. 目录结构与文件格式

每个患者一个文件夹，按颌分为 `upper` / `lower` 两个子目录，里面是同名的 `.obj` 和 `.json`。下载的 6 个分包合并后大致是这样：

```
Teeth3DS/
├── data_part_1 ... data_part_6/   # 合并前的分包
└── (合并后)
    ├── lower/
    │   └── 01A6HAN6/
    │       ├── 01A6HAN6_lower.obj
    │       └── 01A6HAN6_lower.json
    └── upper/
        └── 01A6HAN6/
            ├── 01A6HAN6_upper.obj
            └── 01A6HAN6_upper.json
```

`.obj`：普通三角网格，`v x y z` + `f i j k`，单位 mm，每个扫描十万级顶点。坐标系是口扫仪导出的原始坐标，没有统一对齐。

`.json`：四个字段，`labels` 和 `instances` 的长度都等于 obj 的**顶点**数（逐顶点，不是逐面）。

```
{
  "id_patient": "01A6HAN6",
  "jaw": "lower",
  "labels":    [0, 0, 31, 31, 32, ...],
  "instances": [0, 0, 1,  1,  2,  ...]
}
```

字段	含义
`id_patient`	患者 ID
`jaw`	`"upper"` 或 `"lower"`
`labels`	每个顶点的 FDI 牙位号，0 = 牙龈
`instances`	每个顶点所属的牙齿实例，0 = 牙龈，其余值只用于区分不同牙，数值本身无意义

实例标签的用处：同一模型里可能有两颗牙同一个 FDI 号（多生牙、标注特例），或者做实例分割 / 质心回归时需要按牙分组。

3. FDI 编号体系

FDI（ISO 3950）用两位数编号每颗牙：**十位 = 象限，个位 = 牙位**。象限按患者自己的左右划分，从患者右上开始顺时针（1 右上 → 2 左上 → 3 左下 → 4 右下）；牙位从中线向后数，1 = 中切牙，8 = 第三磨牙（智齿）。例如 36 = 左下第一磨牙，11 = 右上中切牙。

个位	牙名	上颌（右 / 左）	下颌（左 / 右）
1	中切牙	11 / 21	31 / 41
2	侧切牙	12 / 22	32 / 42
3	尖牙	13 / 23	33 / 43
4	第一前磨牙	14 / 24	34 / 44
5	第二前磨牙	15 / 25	35 / 45
6	第一磨牙	16 / 26	36 / 46
7	第二磨牙	17 / 27	37 / 47
8	第三磨牙	18 / 28	38 / 48

乳牙用象限 5–8（51–85）。Teeth3DS 以恒牙为主，转换前先跑一遍第 5 节的标签统计，确认有没有意外的值。

映射成连续类别索引

网络的交叉熵需要 0..C-1 的连续类别，FDI 编号不连续，要先映射。常见两种方案：

方案	类别数	映射规则	适用
A. 上下颌共用（推荐）	17	牙龈 → 0；象限 1/3 的牙位 n → n（1–8）；象限 2/4 的牙位 n → n + 8（9–16）	上下颌各训一个模型，或一个模型 + 颌别输入
B. 全局	33	牙龈 → 0；11–18 → 1–8，21–28 → 9–16，31–38 → 17–24，41–48 → 25–32	不区分上下颌的单模型

方案 A 里上下颌的同一索引对应同一种牙（如 6 = 右上或左下的第一磨牙），推理时用 `jaw` 还原回 FDI：上颌 `1–8 → 11–18`、`9–16 → 21–28`，下颌 `1–8 → 31–38`、`9–16 → 41–48`。



FDI 牙位图 · 4 个象限，32 颗恒牙

竖虚线是中线，编号从中线向两侧递增；横线是咬合面，上方为上颌、下方为下颌。

4. 转换为 npy 的基本思路

核心是把“网格 + 逐顶点标签”变成“固定点数的点云 + 逐点标签”，格式沿用项目现有的分割 npy（`segment/.../preproces_9d_npy.py`），这样 `NPYDataset` 只需改 `label_map`。

1. **读取**：obj 网格 + json 标签，确认标签数等于顶点数。
2. **顶点标签 → 面标签**：每个三角形取 3 个顶点标签的多数票。
3. **表面采样**：均匀采样到固定点数（如 16000），每个点继承所在面的标签与法线，再按项目惯例附加曲率特征。
4. **标签**：npy 里存原始 FDI 号，到 dataset 里再映射成 0..16，换映射方案不用重新生成数据。
5. **批量与校验**：多进程批量转换，完成后统计一遍标签分布，确认没有异常值。
6. **划分**：按患者划分，要和论文对比就用仓库的官方划分列表。

5. 注意事项

- **保持顶点顺序**：trimesh 读取要加 `process=False`，否则顶点被合并重排，标签错位且不报错。
- **镜像增强要换标签**：翻转坐标后必须同时交换左右象限（1↔2、3↔4），否则左右牙全部标反。
- **点数对齐**：均匀采样可能不足目标点数，要补齐，否则拼 batch 报错。
- **划分不泄漏**：同一患者的上下颌和镜像文件必须在同一个集合。
- **姿态未对齐**：原始坐标来自不同口扫仪，靠大角度旋转增强，或先用项目的对齐模型摆正。
- **类别不均衡**：牙龈占多数，智齿样本少，可加类别权重。
- **许可**：CC BY-NC-ND 4.0，仅限非商用研究。